




Σχήμα 0-1 Τυπική χαρακτηριστική καμπύλη κβαντιστή που επιτρέπει την αναπαράσταση πεπερασμένης ακρίβειας των αριθμητικών τιμών έτσι ώστε να είναι δυνατή η αποθήκευσή τους σε καταχωρητές πεπερασμένου μήκους.

Σφάλματα κβαντισμού και υπερχειλίσας

Όπως έχει ήδη αναφερθεί, αν και κατά την περιγραφή των ψηφιακών φίλτρων δεχόμαστε σιωπηρά πως οι τιμές των συντελεστών του φίλτρου και των σημάτων που δέχονται στην είσοδό τους είναι γνωστές με *άπειρη ακρίβεια*, ωστόσο πρακτικά αυτό *δεν είναι δυνατόν να συμβεί*, αφού το μήκος των καταχωρητών των συστημάτων ψηφιακής επεξεργασίας σήματος στους οποίους αποθηκεύονται οι τιμές των συντελεστών του φίλτρου (αφού πρώτα μετατραπούν στο δυαδικό σύστημα, χρησιμοποιώντας κάποια από τις μορφές αναπαράστασης που έχουν περιγραφεί στην προηγούμενη ενότητα), είναι *πεπερασμένο*. Κατά συνέπεια, εάν το σύστημα που χρησιμοποιούμε, διαθέτει καταχωρητές μήκους K bits, τότε θα πρέπει, εκ των πραγμάτων, να αποθηκεύσουμε τις τιμές που μας ενδιαφέρουν χρησιμοποιώντας αυτό το πλήθος από bits, το οποίο σε όλες σχεδόν τις περιπτώσεις, *είναι μικρότερο από το πλήθος των bits της αρχικής αναπαράστασης της τιμής*. Είναι ενδιαφέρον, πως η γνώση του μήκους K των καταχωρητών του ψηφιακού συστήματος, *προσδιορίζει με μοναδικό τρόπο την περιοχή τιμών των αριθμών που μπορούν να χρησιμοποιηθούν από αυτό*. Αυτή η μείωση του πλήθους των bits που χρησιμοποιούνται για την αναπαράσταση των τιμών, αποτελεί ουσιαστικά μία διαδικασία *κβαντισμού*, η οποία οδηγεί στην *μείωση* της ακρίβειας και στην εμφάνιση *σφαλμάτων κβαντισμού*. Η διαδικασία του κβαντισμού έχει περιγραφεί με λεπτομέρεια στις ενότητες παρουσίασης της διαδικασίας μετατροπής ενός αναλογικού σήματος σε ψηφιακό (δείτε ειδικότερα την Ενότητα ?? στη σελίδα ??) και όπως είχαμε σχολιάσει εκεί, η χαρακτηριστική καμπύλη της μη γραμμικής διάταξης του κβαντιστή, έχει τη μορφή που απεικονίζεται στο Σχήμα 0-1. Αυτός ο κβαντιστής χρησιμοποιείται για τον κβαντισμό τιμών που ακολουθούν την *αναπαράσταση σταθερής υποδιαστολής* και η λειτουργία του πραγματοποιείται όπως έχουμε σχολιάσει, με τον ακόλουθο τρόπο: Εάν η τιμή που δέχεται ο κβαντιστής στην είσοδό του, είναι μικρότερη από p (περιοχή A του σχήματος), τότε η έξοδός του είναι μία τιμή η οποία βρίσκεται αρκετά κοντά στην τιμή εισόδου και με την διαφοροποίηση που υφίσταται ανάμεσα σε αυτές τις τιμές, να έγκειται στο γεγονός, πως η είσοδος του κβαντιστή μπορεί να είναι οποιαδήποτε και να χαρακτηρίζεται από άπειρη ακρίβεια, ενώ η έξοδός του αποτελεί μία τιμή η οποία μπορεί να αναπαρασταθεί από το υποκείμενο ψηφιακό σύστημα. Αντίθετα, εάν η είσοδος στον κβαντιστή είναι μεγαλύτερη από p (περιοχή B του σχήματος), τότε η έξοδός του, δεν μπορεί να υπερβεί την τιμή p . Από τις δύο αυτές περιοχές, η περιοχή A αντιστοιχεί στον *κβαντισμό των τιμών του κατάλληλου σήματος*, ενώ η περιοχή B, σχετίζεται με την *διόρθωση που απαιτείται*, όταν ανακλύψουν φαινόμενα υπερχειλίσας. Από τον ορισμό αυτών των δύο διαδικασιών, δεν είναι δύσκολο να γίνει αντιληπτό, πως ο κβαντισμός επηρεάζει τα *λιγότερο σημαντικά bits των αριθμητικών τιμών*, ενώ αντίθετα, η υπερχειλίση επηρεάζει τα *περισσότερο σημαντικά bits* και κατά συνέπεια, προκαλεί πολύ πιο *σφοδρή παραμόρφωση* στο σήμα σε σχέση με τη διαδικασία του κβαντισμού.

Σύμφωνα με τα όσα αναφέραμε παραπάνω, η αναπαράσταση των αριθμητικών τιμών που χρησιμοποιούνται στα ψηφιακά συστήματα με πεπερασμένη ακρίβεια, απαιτεί την προσθήκη *μη γραμμικών διατάξεων* (οι οποίες είναι γνωστές ως *κβαντιστές* και λειτουργούν σύμφωνα με την χαρακτηριστική του Σχήματος 0-1), σε διάφορα σημεία του ιδανικού γραμμικού και χρονικώς αμετάβλητου ψηφιακού συστήματος, το οποίο, επομένως, αποκτά *μη γραμμικά χαρακτηριστικά*. Αυτά τα χαρακτηριστικά καθιστούν την μελέτη του συστήματος *μία σχετικά πολύπλοκη διαδικασία* και για το λόγο αυτό, όπως θα σχολιάσουμε με λεπτομέρεια στη συνέχεια, στην πράξη αντικαθιστούμε τις μη γραμμικές διατάξεις των κβαντιστών, με *πηγές γραμμικού θορύβου*, διαδικασία που απλοποιεί σημαντικά την ανάλυση και καθιστά δυνατό τον υπολογισμό μεγεθών, που υπό άλλες συνθήκες, θα ήταν αδύνατος. Το ερώτημα που τίθεται εντελώς εύλογα σε αυτό το σημείο, είναι *σε ποιες θέσεις μέσα στο σύστημα, θα πρέπει να προσθέσουμε αυτούς τους κβαντιστές*. Η απάντηση είναι εύκολο να δοθεί: *σε κάθε κλάδο ανάδρασης του αναδρομικού ψηφιακού συστήματος, θα πρέπει να προστεθεί τουλάχιστον ένας κβαντιστής*. Αυτό είναι κάτι που χαρακτηρίζει όλα τα σχήματα που παρατίθενται στις σχετικές ενότητες. Το άλλο ερώτημα που επίσης μπορεί να τεθεί, έχει να κάνει με τον *τρόπο μελέτης των φαινομένων του κβαντισμού και της υπερχειλίσας* που χαρακτηρίζουν τη λειτουργία ενός κβαντιστή και σχετίζονται με τις περιοχές A και B του Σχήματος


0-1. Αυτά τα φαινόμενα θα πρέπει να μελετηθούν από κοινού, ή χωριστά και ανεξάρτητα το ένα από το άλλο? Αν και θα ανέμενε κανείς πως ο κβαντισμός και η υπερχειλίση από τη στιγμή που αφορούν στην ίδια διάταξη, θα πρέπει να μελετηθούν από κοινού, στην πραγματικότητα, εφόσον οι τιμές των σημάτων αναπαρίστανται από ένα επαρκές πλήθος δυαδικών ψηφίων, συμβαίνει ακριβώς το αντίθετο. Μάλιστα, είναι ενδιαφέρον να επισημάνουμε, πως εάν οι τιμές των εμπλεκόμενων σημάτων είναι πολύ μεγάλες και ειδικότερα, πολύ μεγαλύτερες από το βήμα κβαντισμού, τότε κατά τη μελέτη της υπερχειλίσης, *μπορούμε να αγνοήσουμε εντελώς τη διαδικασία του κβαντισμού* και να αντικαταστήσουμε την κλιμακωτή καμπύλη της περιοχής Α του Σχήματος **0-1** με μία ευθεία γραμμή με κλίση 45° που διέρχεται από την αρχή των αξόνων. Παρατηρώντας τις χαρακτηριστικές των τριών μηχανισμών ανάκαμψης από την υπερχειλίση που απεικονίζονται στο Σχήμα **??**, διαπιστώνουμε πως τα πράγματα είναι όντως έτσι. Με άλλα λόγια, για τις τιμές των σημάτων που είναι μικρότερες από το κατώφλι της υπερχειλίσης, *ο κβαντιστής θεωρείται ως μία γραμμική διάταξη*, η οποία αφήνει ουσιαστικά αμετάβλητο το σήμα εισόδου, αφού λόγω της πολύ μεγάλης τιμής του σήματος και του πολύ μικρού βήματος κβαντισμού, η διαφορά ανάμεσα στην αρχική τιμή του σήματος και στην κβαντισμένη τιμή, θα είναι πάρα πολύ μικρή. Βέβαια, για να ισχύσουν όλα τα παραπάνω θα πρέπει, όπως σχολιάσαμε, να χρησιμοποιηθεί ένα *σχετικά μεγάλο μήκος καταχωρητών*, που θα οδηγήσει αντίστοιχα σε μία αρκετά μεγάλη τιμή για το συνολικό πλήθος των διαστημάτων κβαντισμού. Ας σημειωθεί, ωστόσο, πως σε κάποιες περιπτώσεις, αυτή η ανεξάρτητη μελέτη των δυο παραπάνω φαινομένων δεν *ενδείκνυται*, αφού κάποιες φορές, η μελέτη των φαινομένων υπερχειλίσης απαιτεί την θεώρηση και χρήση της κλιμακωτής δομής της περιοχής Α του Σχήματος **0-1**, όπως είναι, για παράδειγμα, η εμφάνιση των *οριακών κύκλων* που μελετώνται σε επόμενη ενότητα.

Κβαντισμός με περικοπή και στρογγυλοποίηση


Μιλώντας γενικά, αυτή η διαδικασία του κβαντισμού μπορεί να πραγματοποιηθεί με δύο τρόπους και πιο συγκεκριμένα με *περικοπή* και με *στρογγυλοποίηση*. Η διαδικασία της περικοπής, όπως λέει και το όνομά της, *συνίσταται απλά στην απομάκρυνση των επιπλέον bits*, έτσι ώστε να διατηρηθούν μόνον αυτά που μπορούν να αποθηκευτούν στους καταχωρητές του ψηφιακού συστήματος. Θεωρώντας για παράδειγμα ένα σύστημα με καταχωρητές των 8 bits και έναν αριθμό, ο οποίος μετά την υποδιαστολή περιέχει 12 bits, η αποθήκευσή του είναι δυνατή μόνο εάν θεωρήσουμε μόνο τα 8 πρώτα bits και αγνοήσουμε τα υπόλοιπα 4 bits (δηλαδή, στην γενική περίπτωση, απομακρύνουμε τα bits που βρίσκονται μετά από το λιγότερο σημαντικό bit της αναπαράστασης, το οποίο στο εν λόγω παράδειγμα είναι το όγδοο bit μετά την υποδιαστολή). Εάν, για παράδειγμα, αυτός ο αριθμός είναι ο 0.101101011101 (για διευκόλυνση του αναγνώστη, το όγδοο bit που μας ενδιαφέρει, είναι εκτυπωμένο με έντονη γραφή) το αποτέλεσμα αυτής της διαδικασίας της περικοπής είναι ο αριθμός 0.10110101. Δεν είναι δύσκολο να γίνει αντιληπτό, πως αυτή η διαδικασία οδηγεί σε *μείωση της ακρίβειας και στην εμφάνιση σφάλματος κβαντισμού*, αφού η δεκαδική τιμή του αριθμού πριν την περικοπή, είναι η 0.710205, ενώ η τιμή που προκύπτει μετά την περικοπή, είναι η 0.707031, διαφορά, η οποία είναι σημαντική. Υπάρχουν δύο τύποι περικοπής που εξαρτώνται από τον τρόπο με τον οποίο αναπαρίστανται οι αρνητικοί αριθμοί και ειδικότερα, η *περικοπή μεγέθους* (magnitude truncation) όταν για την αναπαράσταση των αρνητικών αριθμών χρησιμοποιείται το συμπλήρωμα ως προς 1 και η *περικοπή τιμής* (value truncation), όταν για την αναπαράσταση των αρνητικών αριθμών χρησιμοποιείται το συμπλήρωμα ως προς 2, που είναι και αυτή που συνήθως χρησιμοποιείται στην πράξη, αν και η περικοπή μεγέθους χαρακτηρίζεται από το πλεονέκτημα πως *δεν επιτρέπει την εμφάνιση οριακών κύκλων*, όπως σχολιάζουμε αναλυτικά στην οικεία ενότητα. Οι δύο αυτές τεχνικές περικοπής, είναι διαφορετικές μεταξύ τους, αφού στην περικοπή μεγέθους, η διεύθυνση του κβαντισμού είναι *πάντοτε προς το μηδέν* (και κατά συνέπεια, για τους αρνητικούς αριθμούς πραγματοποιείται προς τα επάνω, ενώ για τους θετικούς αριθμούς πραγματοποιείται προς τα κάτω), ενώ στην περικοπή τιμής, η διεύθυνση του κβαντισμού είναι *πάντοτε προς τα κάτω*. Ωστόσο, σε *αμφότερες* τις μεθόδους, το μέτρο του σφάλματος κβαντισμού, δηλαδή της διαφοράς $E = Q(x) - x$ ανάμεσα στην κβαντισμένη τιμή $Q(x)$ και στην αρχική μη κβαντισμένη τιμή x , είναι *πάντοτε μικρότερο* από το βήμα κβαντισμού q .

Από την άλλη πλευρά, η μέθοδος της *στρογγυλοποίησης*, συνίσταται στην *μείωση του μεγέθους ενός δυαδικού αριθμού*, αλλά με τέτοιο τρόπο, ώστε η στρογγυλοποιημένη τιμή που προκύπτει να είναι *όσο το δυνατόν πιο κοντά σε μία τιμή η οποία να μπορεί να αναπαρασταθεί στο ψηφιακό σύστημα που χρησιμοποιείται*. Αυτή η διαδικασία της στρογγυλοποίησης¹ αποτελεί έναν συνδυασμό διαδικασιών περικοπής και πρόσθεσης και πραγματοποιείται με τον ακόλουθο τρόπο. Αρχικά η τιμή του αριθμού υφίσταται περικοπή η οποία πραγματοποιείται με τον τρόπο που περιγράψαμε, διατηρώντας μόνο το κατάλληλο πλήθος από bits και στη συνέχεια εξετάζουμε την τιμή του bit, το οποίο στην αρχική τιμή του αριθμού (δηλαδή πριν την περικοπή), βρίσκονταν *μετά το λιγότερο σημαντικό bit* του αριθμού μετά την περικοπή. Εάν αυτό το bit έχει τιμή 0 δεν κάνουμε τίποτε (ή ισοδύναμα, προσθέτουμε στο λιγότερο σημαντικό bit την τιμή 0), ενώ εάν αυτό το bit είναι ίσο με 1, προσθέτουμε στο λιγότερο σημαντικό bit την τιμή 1. Στο παραπάνω παράδειγμα, το bit της αρχικής τιμής που βρίσκεται μετά το όγδοο bit, δηλαδή το ένατο bit, έχει την τιμή 1 και κατά συνέπεια, για την πραγματοποίηση της στρογγυλοποίησης, θα πρέπει να προσθέσουμε στο όγδοο bit την τιμή 1 (παρατηρήστε πως αυτό το όγδοο bit έχει και αυτό την ίδια τιμή). Το αποτέλεσμα αυτής της διαδικασίας, είναι ο δυαδικός αριθμός 0.10110110 που αντιστοιχεί στον δεκαδικό αριθμό 0.7109375. Παρατηρήστε, πως *αν και η τιμή που προέκυψε, είναι ελαφρά μεγαλύτερη από την αρχική τιμή πριν τον κβαντισμό*, ωστόσο, είναι *πολύ πιο κοντά σε αυτή*. Μιλώντας γενικά, αυτή η μέθοδος της στρογγυλοποίησης, οδηγεί σε *καλύτερα αποτελέσματα σε σχέση με την μέθοδο της περικοπής*, αφού το μέτρο του σφάλματος κβαντισμού είναι μικρότερο του $q/2$ και όχι μικρότερο του q , όπως συμβαίνει στις δύο μεθόδους της περικοπής και για

¹Είναι ενδιαφέρον να επισημάνουμε, πως η διαδικασία της στρογγυλοποίησης σε ορισμένες περιπτώσεις πραγματοποιείται υπό συνθήκες ελέγχου (controlled rounding, CR). Στην περίπτωση αυτή, ο τρόπος με τον οποίο πραγματοποιείται ο χειρισμός του λιγότερου σημαντικού bit δεν υπαγορεύεται από την τιμή του ίδιου του σήματος που υφίσταται τη διαδικασία του κβαντισμού, σύμφωνα με τα όσα περιγράψαμε παραπάνω, αλλά αντίθετα ελέγχεται από κάποιο άλλο σήμα, το οποίο είτε είναι κάποιο εξωτερικό και σε όλες σχεδόν τις περιπτώσεις, στοχαστικό σήμα, είτε κάποιο από τα εσωτερικά σήματα του υποκείμενου ψηφιακού συστήματος. Σε πιο περίπλοκες περιπτώσεις, η απόφαση σχετικά με το εάν η στρογγυλοποίηση πραγματοποιηθεί προς τα επάνω ή προς τα κάτω, ελέγχεται από περισσότερα του ενός σήματα ελέγχου, ένα από τα οποία μπορεί να είναι και το ίδιο το σήμα που υφίσταται τον κβαντισμό.



Σχήμα 0-2 Οι χαρακτηριστικές εισόδου - εξόδου για το κβαντισμό με στρογγυλοποίηση (αριστερή εικόνα) με περικοπή τιμής (μεσαία εικόνα) και με περικοπή μεγέθους (δεξιά εικόνα).




Σχήμα 0-3 Η μεταβολή του σφάλματος κβαντισμού για κβαντισμό με στρογγυλοποίηση (αριστερή εικόνα) και για κβαντισμό με περικοπή μεγέθους (δεξιά εικόνα) (Butterweck, 1979, Σχήμα 2).

τον λόγο αυτό, γενικά προτιμάται στην πράξη. Είναι ενδιαφέρον, ωστόσο, να επισημάνουμε, πως εάν προσθέσουμε στο αρχικό μη κβαντισμένο σήμα την τιμή $q/2$, οι μέθοδοι της στρογγυλοποίησης και της περικοπής τιμής *οδηγούν στο ίδιο αποτέλεσμα*. Το Σχήμα 0-2 παρουσιάζει τις χαρακτηριστικές εισόδου - εξόδου για αυτές τις τρεις μεθόδους κβαντισμού. Από την άλλη πλευρά, το Σχήμα 0-3 απεικονίζει το σφάλμα κβαντισμού για τη στρογγυλοποίηση (αριστερή εικόνα) και για την περικοπή μεγέθους (δεξιά εικόνα).


Σημειώστε, πως αν και σε αμφότερες τις περιπτώσεις, η κατάσταση που ανακύπτει είναι *ντετερμινιστική* ως προς τη φύση της, υπό την έννοια πως *με κάθε σήμα εισόδου σχετίζεται ένα και μοναδικό σήμα σφάλματος*, ωστόσο, μιλώντας γενικά, αρκετές φορές τείνουμε να προσδώσουμε στη διαδικασία της στρογγυλοποίησης, έναν *βαθμό τυχαιότητας*, υπό την εξής έννοια. Εάν θεωρήσουμε πως το σήμα $x[n]$ αναπαριστά μία *στάσιμη τυχαία διεργασία* (δείτε την Ενότητα ?? στη σελίδα ??) που χαρακτηρίζεται από πυκνότητα πιθανότητας $P(x)$ και από συνάρτηση αυτοσυσχέτισης $r_{xx}[m] = E\{x[n]x[n-m]\}$, αυτή η διεργασία κάτω από την επίδραση της χαρακτηριστικής που σχετίζεται με το σφάλμα στρογγυλοποίησης, μετασχηματίζεται σε *μία άλλη τυχαία διεργασία* $y[n]$, η οποία σχεδόν πάντοτε διαθέτει *χαρακτηριστικά λευκού θορύβου* με συνάρτηση αυτοσυσχέτισης $r_{yy}[n] = (\Delta^2/12)\delta[n]$ και ομοιόμορφη πυκνότητα πιθανότητας στην περιοχή τιμών $-\Delta/2 \leq E \leq \Delta/2$, όπου Δ είναι το βήμα κβαντισμού. Αυτό είναι κάτι που ισχύει ιδιαίτερα για την περίπτωση *οποιοδήποτε μη περιοδικού σήματος* το μήκος λέξης του οποίου *μειώνεται* κατά έναν σημαντικό αριθμό από bits. Σε μία ισοδύναμη περιγραφή, τα σήματα σφάλματος που δημιουργούνται από τους κβαντιστές, μπορούν να μοντελοποιηθούν με αρκετά μεγάλη ακρίβεια ως *λευκός θόρυβος*, ο οποίος είναι *ασυσχέτιστος* τόσο με όλα τα σήματα θορύβου όσο και με το σήμα που διακινείται στο φίλτρο, ενώ το ίδιο ισχύει και για τον θόρυβο που εμφανίζεται στην έξοδο του φίλτρου. Αυτή η ιδιότητα αποτελεί τη βάση πάνω στην οποία στηρίζεται η *στατιστικής φύσεως αντιμετώπιση του σφάλματος στρογγυλοποίησης*, μέσω ενός μοντέλου *λευκού θορύβου*, η οποία περιγράφεται σε άλλη ενότητα. Από την άλλη πλευρά, ωστόσο, όταν ο κβαντισμός στηρίζεται στην τεχνική της *περικοπής μεγέθους*, τότε οι επιμέρους πηγές θορύβου, είναι συσχετισμένες τόσο μεταξύ τους όσο και με το διακινούμενο σήμα, ενώ το ίδιο ισχύει και για τον θόρυβο στην έξοδο του φίλτρου. Μία λύση στο πρόβλημα αυτό, που προτάθηκε από τους Claassen et. al² συνίσταται στην *προσθήκη μίας γραμμικής παραμόρφωσης στο σήμα εισόδου*, η οποία οδηγεί σε ένα σήμα θορύβου κβαντισμού με χαμηλότερη ισχύ σε σχέση με το αρχικό σήμα, το οποίο είναι ορθογώνιο στο σήμα του φίλτρου, αλλά εξακολουθεί να είναι συσχετισμένο με αυτό. Ο Butterweck προχώρησε ένα βήμα πιο πέρα, αφού αφαιρώντας ένα γραμμικώς συσχετισμένο σήμα από το κβαντισμένο σήμα, δημιούργησε ένα σήμα θορύβου το οποίο *αφενός μεν έχει ακόμη πιο μικρή ισχύ σε σχέση με το προηγούμενο σήμα, αφετέρου είναι ασυσχέτιστο με το σήμα του φίλτρου*³.

² Δείτε την αναφορά Claassen T.A.C.M, Mecklenbräuker W.F.G & Peek J.B.H, *Quantization Noise Analysis for Fixed Points Digital Filters Using Magnitude Truncation for Quantization*, IEEE Transactions on Circuits and Systems, vol. CAS-22, pp. 887-895, November 1975.

³ Δείτε την αναφορά Butterweck H.J, *On the Quantization Noise Contributions in Digital Filters which are Uncorrelated with the Output Signal*, IEEE Transactions of Circuits and Systems, vol. CAS-26, No. 11, November 1979, pp. 901-910.



Σχήμα 0-4 Η ανάλυση της χαρακτηριστικής σφάλματος για την περικοπή μεγέθους σε δύο τμήματα εκ των οποίων το πρώτο μπορεί να περιγραφεί από ένα μοντέλο λευκού θορύβου ενώ το δεύτερο είναι μη γραμμικό και σχετίζεται σε ισχυρό βαθμό με το σήμα εισόδου Butterweck, Ritzerfeld & Werter, Σχήμα 2.2).



Σχήμα 0-5 Τα μοντέλα λευκού θορύβου για τα σφάλματα κβαντισμού ο οποίος πραγματοποιείται με στρογγυλοποίηση (επάνω εικόνα) και περικοπή μεγέθους (κάτω εικόνα).

Από την άλλη πλευρά, η χαρακτηριστική σφάλματος για την περίπτωση της περικοπής μεγέθους, μπορεί να συσχετιστεί με την χαρακτηριστική σφάλματος της στρογγυλοποίησης, αναλύοντάς την σε δύο τμήματα, τα οποία αμφότερα απεικονίζονται στο Σχήμα 0-4 (πατηρήστε πως ο συνδυασμός των δύο καμπυλών αυτού του σχήματος, που συνίσταται στην πρόσθεση των τιμών των τεταγμένων των αντίστοιχων σημείων των δύο καμπυλών, οδηγεί στην χαρακτηριστική σφάλματος για την περικοπή μεγέθους που απεικονίζεται στην δεξιά εικόνα του Σχήματος 0-3). Δεν είναι δύσκολο να παρατηρήσει κανείς, πως η αριστερή εικόνα του Σχήματος 0-4, μοιάζει πάρα πολύ με την χαρακτηριστική σφάλματος του κβαντισμού με στρογγυλοποίηση (αφού απλά είναι μετατοπισμένη οριζόντια κατά απόσταση $q/2$) και κατά συνέπεια, μπορεί να υιοθετηθεί και για αυτή, το μοντέλο του λευκού θορύβου. Αξίζει να σημειωθεί, πως το σφάλμα κβαντισμού μέσω περικοπής μεγέθους, σχετίζεται ισχυρά με το σήμα εισόδου, αφού αυτά τα μεγέθη έχουν αντίθετα πρόσημα, ή σε μαθηματική γραφή, $\text{sign}[e(x)] = -\text{sign}(x)$, αν και η προσθήκη του όρου $(1/2)\text{sign}(x)$ σε αυτό το σφάλμα, οδηγεί στην συσχέτιση των χαρακτηριστικών που περιγράψαμε προηγουμένως. Κατά συνέπεια, η στρογγυλοποίηση και η περικοπή μεγέθους, διαφέρουν ουσιαστικά μεταξύ τους μόνο ως προς το δεύτερο τμήμα της καμπύλης, το τμήμα - πρόσημου (sign-part), το οποίο αποτελεί μία μη γραμμική συνιστώσα που όπως σχολιάσαμε, σχετίζεται σε πολύ μεγάλο βαθμό με το σήμα εισόδου. Αυτή η συνιστώσα του σφάλματος, είναι αυστηρά ντετερμινιστικής φύσεως, σε αντίθεση με την άλλη συνιστώσα, για την οποία δεν είναι δυνατόν να δοθεί μία στατιστική περιγραφή, αν και στην περίπτωση κατά την οποία το σήμα εισόδου είναι ένα αμιγώς τυχαίο σήμα, αυτή η δυνατότητα υφίσταται και για αυτό το σφάλμα.

Τα μοντέλα λευκού θορύβου για τα σφάλματα που σχετίζονται με την στρογγυλοποίηση και την περικοπή μεγέθους απεικονίζονται στο Σχήμα 0-5.

Περιοχές τιμών για τα σφάλματα κβαντισμού

Ας συμβολίσουμε με E_t και E_r τα σφάλματα κβαντισμού που προκύπτουν ως αποτέλεσμα της εφαρμογής των διαδικασιών της περικοπής και της στρογγυλοποίησης οι οποίες απαιτούνται για την αναπαράσταση ενός δυαδικού αριθμού με τιμή X μήκους ℓ bits, χρησιμοποιώντας ℓ' bits με $\ell' < \ell$ και οδηγούν σε μία νέα τιμή X' . Ας θεωρήσουμε επίσης, έναν αριθμό της μορφής 0.xxxxxx κωδικοποιημένο στο δυαδικό σύστημα, ο οποίος διαθέτει μόνο κλασματικό μέρος, αφού, όπως αναφέραμε, όλοι οι αριθμοί μπορούν να μετασχηματιστούν σε αυτήν τη μορφή, όταν χρησιμοποιείται αναπαράσταση κινητής υποδιαστολής. Στην πραγματικότητα, η χρήση αριθμών εκπνερασμένων σε αυτή τη μορφή είναι επιβεβλημένη, αφού αποδεικνύεται πως η χρήση ακέραιων αριθμών οδηγεί σε πολύ μεγάλο σφάλμα κβαντισμού, ενώ η χρήση μικτών αριθμών (δηλαδή αριθμών που περιέχουν τόσο ακέραιο όσο και κλασματικό μέρος) αυξάνει τον βαθμό της πολυπλοκότητας όσον αφορά στην πράξη του πολλαπλασιασμού. Δεν είναι δύσκολο να γίνει αντιληπτό πως η περιοχή τιμών για τα παραπάνω σφάλματα κβαντισμού που αμφότερα ορίζονται ως $X' - X$, θα είναι διαφορετική για τον καθέναν από τους τύπους της αναπαράστασης που χρησιμοποιούνται, ενώ η τιμή αυτού του σφάλματος θα εξαρτάται από την σχέση που υφίσταται ανάμεσα στις τιμές ℓ και ℓ' του πλήθους των bits που χρησιμοποιούνται

πριν και μετά τον κβαντισμό. Στην περιγραφή που ακολουθεί θα περιοριστούμε στις αναπαραστάσεις πρόσημου μεγέθους και συμπληρώματος ως προς 2.

Ξεκινώντας από την αναπαράσταση πρόσημου μεγέθους, εάν ο κβαντισμός πραγματοποιείται μέσω περικοπής και η τιμή του X είναι θετική, τότε η νέα τιμή θα είναι πάντοτε μικρότερη από την αρχική, ενώ το σφάλμα E_t θα έχει πάντοτε αρνητική τιμή η οποία εμπίπτει στην περιοχή

$$-(2^{-\ell'} - 2^{-\ell}) \leq E_t \leq 0$$

με τη μέγιστη τιμή αυτού του σφάλματος να αντιστοιχεί στην περίπτωση εκείνη κατά την οποία τα $\ell - \ell'$ το πλήθος bits που απομακρύνονται από τον αριθμό, να έχουν όλα την τιμή 1. Από την άλλη πλευρά, εάν η τιμή του X είναι αρνητική, τότε η τιμή του σφάλματος θα είναι θετική, αφού η περικοπή κλασματικών ψηφίων ενός αρνητικού αριθμού, οδηγεί σε αύξηση της τιμής του, με την περιοχή τιμών του σφάλματος E_t να είναι η

$$0 \leq E_t \leq (2^{-\ell'} - 2^{-\ell})$$

Συνδυάζοντας όλα τα παραπάνω, οδηγούμαστε στο συμπέρασμα, πως για την περίπτωση των θετικών και αρνητικών αριθμών για τους οποίους χρησιμοποιείται η αναπαράσταση πρόσημου μεγέθους, το σφάλμα περικοπής E_t λαμβάνει τιμές σε μία περιοχή η οποία είναι συμμετρική γύρω από τη μηδενική τιμή, αφού ο συνδυασμός των δύο παραπάνω συνθηκών μας επιτρέπει να γράψουμε ότι

$$-(2^{-\ell'} - 2^{-\ell}) \leq E_t \leq (2^{-\ell'} - 2^{-\ell})$$

Αντίθετα, στην περίπτωση της αναπαράστασης του συμπληρώματος ως προς 2, αυτή η συμμετρία δεν υφίσταται. Ειδικότερα, για τους θετικούς αριθμούς ισχύει ότι και πριν (αφού όπως σχολίασαμε, η διαφοροποίηση όσον αφορά στον τύπο της αναπαράστασης, περιορίζεται μόνο στους αρνητικούς αριθμούς), ενώ για τους αρνητικούς αριθμούς η διαδικασία της περικοπής έχει ως αποτέλεσμα την αύξηση της τιμής του αρνητικού αριθμού (αφού ο αρνητικός αριθμός προκύπτει αφαιρώντας από το 2 τον αντίστοιχο θετικό αριθμό). Με άλλα λόγια, το σφάλμα E_t θα είναι πάντοτε αρνητικό και θα λαμβάνει τιμές στην περιοχή

$$-(2^{-\ell'} - 2^{-\ell}) \leq E_t \leq 0$$

η οποία ισχύει επίσης και για την περίπτωση των θετικών αριθμών, σύμφωνα με τα όσα αναφέραμε προηγουμένως.

Στην περίπτωση κατά την οποία η μέθοδος κβαντισμού που χρησιμοποιείται, δεν είναι η περικοπή αλλά η στρογγυλοποίηση, το σφάλμα κβαντισμού E_t σχετίζεται μόνο με το μέγεθος του αριθμού και κατά συνέπεια, είναι ανεξάρτητο από τον τύπο της αναπαράστασης. Στην περίπτωση αυτή, το μέγιστο σφάλμα που θα προκύψει είναι ίσο με $\frac{1}{2}(2^{-\ell'} - 2^{-\ell})$ και μπορεί να είναι τόσο θετικό, όσο και αρνητικό. Επομένως, η περιοχή τιμών του σφάλματος στην περίπτωση αυτή, είναι η

$$-\frac{1}{2}(2^{-\ell'} - 2^{-\ell}) \leq E_t \leq \frac{1}{2}(2^{-\ell'} - 2^{-\ell})$$

Τα όσα αναφέραμε παραπάνω, αφορούν στην αναπαράσταση σταθερής υποδιαστολής, ενώ στην αναπαράσταση κινητής υποδιαστολής, τα πράγματα είναι διαφορετικά, αφού σε αυτόν τον τύπο αναπαράστασης, η ανάλυση είναι ανάλογη του μεγέθους του αριθμού στον οποίο εφαρμόζουμε την διαδικασία του κβαντισμού. Κατά συνέπεια, το σφάλμα κβαντισμού θα είναι και αυτό ανάλογο της τιμής X , έτσι ώστε να μπορούμε να γράψουμε ότι $E = X' - X = \lambda X$, με την παράμετρο λ να είναι γνωστή ως το σχετικό σφάλμα. Δεν είναι δύσκολο να γίνει αντιληπτό, πως στην αναπαράσταση κινητής υποδιαστολής, η διαδικασία του κβαντισμού θα εφαρμοσθεί στον συντελεστή M και όχι στον εκθέτη E και μπορεί να πραγματοποιηθεί τόσο με περικοπή, όσο και με στρογγυλοποίηση. Ειδικότερα, στην περίπτωση των θετικών αριθμών και για την αναπαράσταση του συμπληρώματος ως προς 2, εάν ο κβαντισμός του συντελεστή πραγματοποιηθεί με περικοπή, θα είναι $-2^E 2^{-\ell'} < \lambda x < 0$ και επειδή είναι $2^{E-1} \leq X < 2^E$, τελικά προκύπτει ότι $-2^{-\ell'+1} < \lambda \leq 0$. Από την άλλη πλευρά, για τους αρνητικούς αριθμούς θα έχουμε $0 \leq \lambda X < 2^E 2^{-\ell'}$ και επομένως $0 \leq \lambda < 2^{-\ell'+1}$. Αντίθετα, εάν ο κβαντισμός του συντελεστή πραγματοποιηθεί με στρογγυλοποίηση, τότε το σφάλμα θα είναι συμμετρικό σε σχέση με τη μηδενική τιμή, με μέγιστη τιμή ίση με $\pm 2^{-\ell'}/2$. Θα είναι λοιπόν

$$-\frac{1}{2} 2^{-E} 2^{-\ell'} < \lambda X < \frac{1}{2} 2^{-E} 2^{-\ell'} \quad \text{και επομένως} \quad -2^{-\ell'} < \lambda < 2^{-\ell'}$$

Από την άλλη πλευρά, σε αντίθεση με τα σφάλματα κβαντισμού τα οποία δεν είναι δυνατόν να εξαλειφθούν, αυτό δεν ισχύει για την υπερχειλίση, αφού αυτή μπορεί να αποφευχθεί εντελώς, αν χρησιμοποιήσουμε σήματα εισόδου με κατάλληλα επιλεγμένες μικρές τιμές. Μάλιστα, στην βιβλιογραφία, μπορούν να βρεθούν εκφράσεις για το άνω όριο των τιμών του σήματος εισόδου, που εάν δεν ξεπεραστεί, τότε το φαινόμενο της υπερχειλίσης, εγγυημένα, δεν εμφανίζεται. Ορισμένες από αυτές τις εκφράσεις, οι οποίες σχετίζονται με το χαρακτηριστικό της κλιμάκωσης, παρουσιάζονται στην Ενότητα ?? (ανατρέξτε στη σελίδα ??). Ωστόσο, γενικά, στην πράξη, είναι δυνατόν να δεχθούμε την πιθανότητα εμφάνισης υπερχειλίσης σε κάποιες ειδικές περιπτώσεις σημάτων εισόδου που εμφανίζονται πολύ σπάνια, δεχόμενοι σιωπηρά, πως μετά την εμφάνιση της υπερχειλίσης, το σύστημα θα επανέλθει και μάλιστα με μεγάλη ταχύτητα, στις συνήθεις συνθήκες λειτουργίας. Αυτή η ανάκαμψη από την κατάσταση υπερχειλίσης, που εντελώς εύλογα μπορεί να θεωρηθεί ως ένας τύπος ευστάθειας, αποτελεί ένα από τα πιο σημαντικά προβλήματα που σχετίζονται με αυτό το θέμα και μπορεί να μελετηθεί τόσο υπό συνθήκες μηδενικής εισόδου, όσο και υπό συνθήκες μη μηδενικής εισόδου. Στην πρώτη περίπτωση, η ευστάθεια ορίζεται ως η πλήρης απουσία αυθόρμητων και κυρίως περιοδικών ταλαντώσεων, με το σύστημα να συμπεριφέρεται με γραμμικό τρόπο και να προσεγγίζει εκθετικά ένα σημείο ισορροπίας, στο οποίο όλες οι καταστατικές μεταβλητές τείνουν να λάβουν μηδενική τιμή. Από την άλλη πλευρά, η δεύτερη περίπτωση, σχετίζεται με μία ειδική κατηγορία

σημάτων εισόδου $x[n]$, τα οποία ορίζονται με την βοήθεια του ιδανικού γραμμικού συστήματος και χαρακτηρίζονται από την ιδιότητα πως υπάρχει τουλάχιστον ένα σύνολο αρχικών συνθηκών, για τις οποίες το κατώφλι που σχετίζεται με την εμφάνιση της υπερχειλίσσης, δεν πρόκειται ποτέ να προσεγγιστεί. Στην περίπτωση αυτή, το σύστημα έχει την ικανότητα να “ξεχάσει” όσες υπερχειλίσσεις έχουν πραγματοποιηθεί στο παρελθόν και να ανακάμψει πλήρως, συνεχίζοντας τη λειτουργία του.